

Modelo LSTM de predicción de éxito de las ventas para empresas B2B

1st Matos Manguinuri, Steve Sader 2st Pastor Guerrero, Diego Alejandro 3st Taipe Carrión, Erick Rafael Camilo
Facultad de Ingeniería de Sistemas e Informática Facultad de Ingeniería de Sistemas e Informática Facultad de Ingeniería de Sistemas e Informática
Universidad Nacional Mayor de San Marcos Universidad Nacional Mayor de San Marcos Universidad Nacional Mayor de San Marcos
Lima, Perú Lima, Perú Lima, Perú
steve.matos@unmsm.edu.pe diego.pastor@unmsm.edu.pe erick.taipe@unmsm.edu.pe

1st Postigo Vega, Abel Sebastian
Facultad de Ingeniería de Sistemas e Informática
Universidad Nacional Mayor de San Marcos
Lima, Perú
abel.postigo@unmsm.edu.pe

Abstract—El propósito de esta investigación es construir un modelo de predicción de ventas para empresas orientada a servicios utilizando el enfoque de deep learning, que ha ganado una atención significativa en los últimos años. El presente estudio utiliza datos de ventas de una empresa privada llamada Seminarium Peru, en el cual los datos están un rango 3 años de antigüedad (40292 instancias) de lo cual servirá para construir un modelo de predicción de ventas que, dadas las variables mas relevantes de una venta en particular, predice el éxito de esta venta. Por lo que en esta investigación proponemos el diseño de un modelo LSTM y de ahí se validará el dataset de la empresa de esta investigación lo cual logró una tasa de error cuadrático medio de predicción de venta de 0.0200.

Index Terms—Modelo Híbrido, Predicción de Ventas, LSTM, Empresas B2B.

I. INTRODUCCION

Realizando una revisión a las literaturas sobre la predicción de ventas y predicción de clientes, en los últimos años ha habido varias investigaciones que buscaron nuevos métodos y formas de resolver el problema de la predicción de ventas y de predicción de clientes de forma separada. Para la de predicción de ventas se usaron modelos como ARIMA pero ese modelo de forma individual ha sido descartado últimamente por su falta de precisión al ser solo un modelo estadístico, y donde actualmente otras investigaciones proponen modelos usando deep learning [1] [2], fusiones de técnicas [3] [4], nuevo modelos basados en Deep learning [5] [6] [7], frameworks [8] y arquitecturas [9] para la predicción de ventas. También en los últimos años se ha tomado en cuenta la predicción de clientes [10] [11] [12] [13] [14] como una gran oportunidad para mejorar el flujo de ventas.

En la investigación [7] aplicaron un modelo de clasificación bayesiana usando TAN Bayes pero solo usaron las variables más relevantes y finales de la venta, mas no usaron variables como las del cliente o las variables de todo un flujo de ventas, lo cual permitiría mejorar la predicción no solo de la venta sino también la predicción de la demanda que en este caso es de la empresa HP.

Indica un modelo híbrido entre ARIMA y RNN [4] que puede mejorar la predicción de las ventas diarias de una forma abismal y la dataset de apple que usaron pesar de que tenía cantidad decente de datos (6758 para ser más exactos), a parte que era de dominio público, solo tenía data con dos atributos(fecha diaria, la cantidad de dinero que se vendió ese día), por cada instancia pero no tomo en cuenta otras variables presentes en una venta como la actividad económica del cliente, tipos de productos que se vendieron, entre otros que se usaran en esta investigación y también el data set no es de un ambiente real, por ende, su aplicación no hace un aporte de manera exacta a la investigaciones de los modelos de predicción de venta

También en otras investigaciones como [15] solo se prioriza la predicción de ventas en periodos mensuales, lo cual es un rango grande para poder determinar las ventas y con lleva a que la predicción de ventas sea algo obsoleta porque la predicción de ventas se debe tratar de hacer en el rango más corto posible para poder tomar decisiones más efectivas y rápidas tanto a nivel administrativo como a nivel de áreas comerciales, además que incluso teniendo información del ERP que comenta en [15] se podría aplicar con más precisión la predicción de la venta en una rango mucho menor (por

ejemplo de forma diaria) usando las variables que almacena el ERP , que lo más seguro , en experiencia de este lector de uso de ERPS , contendrá variables sumamente importantes del cliente y del flujo de la venta y que se usaría para mejorar la precisión, por lo que es posible incluso hacer predicciones individuales de cada venta.

Muchas empresas sufren un síndrome crónico en el que sus pronósticos de CRM se convierten en un registro histórico y no en una guía para el futuro [16], estos datos al final se desperdician y no se usan para futuras predicciones de las próximas ventas.

Con inteligencia artificial (IA) y aprendizaje automático (ML), las marcas y las agencias pueden proporcionar los datos correctos a la persona adecuada en el momento adecuado. Estas tecnologías permiten métodos automatizados y escalables para unir las fuentes de datos y luego proporcionar información sobre cómo y dónde el usuario lo necesita [17] , por ende, aplicar IA y ML al mundo de los negocios es una de las mejores ideas en cuestión de saber si tu producto y/o servicio está dando los resultados que esperabas.

Si bien la mayoría de los especialistas en marketing son expertos en leer informes y métricas estándar, pocos están capacitados para analizar datos de múltiples fuentes con la suficiente profundidad para informar mejores decisiones de negocios [17] , esto impide que sea difícil para el área de marketing puedan interpretar fácilmente la gran cantidad de datos que sea vengan de varias fuentes y da por consecuencia que el área de ventas es la más perjudicada con este decisión puesto que ellos son la parte operatoria y provocara que su área tenga que captar clientes ciegamente. Entonces el acceso a la inteligencia de marketing puede ayudar a las organizaciones a tomar decisiones más informadas sobre el gasto en publicidad para futuras campañas, segmentación de audiencia, combinación óptima de canales, etc [17]. Se refiere sobre todo a los conocimientos aplicando IA al área de marketing, esto repercute en un ahorro enorme de los gastos de marketing y también un ahorro de horas hombre del área de ventas. Algunos autores como. [18] nos indica que, si desea generar más oportunidades de marketing de contenido este año, entonces céntrese en la calidad y la investigación de mercado. Tómese el tiempo para comprender realmente a su público objetivo y crear contenido de alta calidad que ayude a resolver sus problemas y les brinde un valor real. Por ende, en lugar de usar probabilidades fijas basadas en la etapa para pronosticar los ingresos, es mejor realizar un seguimiento continuo del progreso y use una curva de campana con alimentación continua para predecir las probabilidades de éxito de un acuerdo determinado en función de su tamaño y edad. En otras palabras, simplemente contando la frecuencia de las operaciones ganadas como un porcentaje de todas las ofertas, cualquier nueva oferta se puede trazar con mayor precisión [16], lo cual se significa una serie de predicciones a nivel de ventas, por lo que hay grandes avances en el uso

de IA para el área de ventas.

Por último, también nos indican que las predicciones de ventas más precisas son importantes para negocios individuales y para nuestra economía [16], lo cual significa más ganancia a menor costo, además muchos de los algoritmos de inteligencia artificial pueden usarse para impulsar el proceso de toma de decisiones de cualquier compañía, lo que lo ayuda a realizar mejores predicciones de negocios [19]. Además, que los gerentes de ventas enfrentan el enorme desafío de tratar de predecir dónde caerán los números de ventas totales de su equipo cada trimestre. Al usar un algoritmo de AI, los gerentes ahora pueden predecir con un alto grado de precisión los ingresos del próximo trimestre [19], pero sería más preciso si se aplicara a las ventas de forma individual más que al trimestre.

Puede gastar mucho dinero en mercadotecnia para aquellos que no compran, o puede usar un algoritmo de inteligencia artificial para ayudar a identificar cuál de sus clientes existentes es más probable que compre una versión mejor de la que posee actualmente (venta adicional) y / o que es más probable que deseen una nueva oferta de productos en conjunto (venta cruzada) [19], esto permitiría hacer una captación de cliente más personalizada. Lo cual en este trabajo de investigación se quiere mejorar esa captación del cliente en las primeras etapas del proceso de ventas.

En conclusión, siempre la predicción de la venta ha sido un tema vital para cualquier empresa. Entonces la aplicación de una IA al área de ventas afectará de forma positiva a los ingresos de la empresa y también un ahorro enorme de horas hombres al área de ventas.

Por lo que el objetivo de esta investigación es diseñar un modelo predictivo para el éxito de una venta en particular. Por ende, primero se diseñará y construirá el modelo, de ahí se validará con el Dataset propio de esta investigación.

El resto de este documento esta organizado de la siguiente manera. La sección II de este documento aborda el trabajo relacionado. La sección III nos muestra el modelo de predicción de ventas que se realizo en esta investigación. La sección IV mostramos el proceso de cómo se hará la predicción de venta de forma global. La sección V describe nuestra evaluación experimental y resultados. La sección VI nos muestra la discusión con otras investigaciones referidos al tema de ventas y por último comentamos las conclusiones y discutimos del alcance futuro.

II. TRABAJO RELACIONADOS

A. Modelos híbridos de ventas

En distintas investigaciones se usaron varias técnicas de deep learning para la predicción de ventas [1] [2] y también nuevos modelos [5] [6] [7].

En [1] se aplica deep learning a través de un DNN y se usa

las variables más que todo del producto para poder predecir la cantidad de productos que se venderá de forma individual de acuerdo a 10 variables descritas en la misma investigación [1]. También [2] usa otra técnica de deep learning , el cual es PRNN , y mencionan que esta técnica supera a técnicas como SARIMA y ETS pero no a otros como MR ni E , por ende es un alternativa viable pero aún falta su aplicación en un gran conjunto de series de tiempo de ventas.

En cambio en la predicción de ventas [5] usaron el método multifuncional Holt-Winters y el método aditivo Holt-Winters pero en un modelo de predicción de ventas mensual usando data de un sistema ERP a diferencia de [6] que propone un nuevo modelo llamado TADA que consta de un codificador LSTM basado en tareas múltiples y el decodificador LSTM basado en la atención dual y lo puede predecir en diferentes series de tiempo , ademas que usa dos dataset (OSW y Favorita) para poder contractar los resultados de la aplicación del modelo en diferentes contexto lo cual supera en aspecto de cantidad y variedad de data a la investigación [5].

B. Técnicas de predicción de ventas

En distintas investigación se usaron varias técnicas de deep learning para la predicción de ventas [1] [2] y también nuevos modelos [5] [6] [7] . En [1] se aplica deep learning a través de un DNN y se usa las variables más que todo del producto para poder predecir la cantidad de productos que se venderá de forma individual de acuerdo a 10 variables descritas en la misma investigación [1] . También [2] usa otra técnica de deep learning , el cual es PRNN , y mencionan que esta técnica supera a técnicas como SARIMA y ETS pero no a otros como MR ni E , por ende es un alternativa viable pero aún falta su aplicación en un gran conjunto de series de tiempo de ventas. En cambio en la predicción de ventas [5] usaron el método multifuncional Holt- Winters y el método aditivo Holt-Winters pero en un modelo de predicción de ventas mensual usando data de un sistema ERP a diferencia de [6] que propone un nuevo modelo llamado TADA que consta de un codificador LSTM basado en tareas múltiples y el decodificador LSTM basado en la atención dual y lo puede predecir en diferentes series de tiempo , ademas que usa dos dataset (OSW y Favorita) para poder contractar los resultados de la aplicación del modelo en diferentes contexto lo cual supera en aspecto de cantidad y variedad de data a [5]

C. Técnicas de predicción de clientes

En distintas investigaciones se usaron varias técnicas de deep learning para la predicción de clientes [11] [12] y también proponen nuevos modelos basados de Machine Learning [13] [14], o el uso de técnicas y modelos en un contexto nuevo [23].

En [11] se usó las variables de los clientes junto con el clima para ver el flujo de clientes a diferencia [12] que aplica más a las variables de los POS además que a diferencia de otras investigaciones se usó variables de regularizaciones para poder

corregir.

Para el problema de la predicción de flujo de clientes , En [13] se aplicó el uso de clasificadores lineales y clasificadores basados pero solo usa el historial de comportamiento de cliente a diferencia de [14] que comenta que no solo los tiempos de clic, el tiempo de duración son los únicos factores que pueden demostrar las preferencias de los usuarios y es más estos son solo una parte de los factores que pueden demostrar las preferencias de los usuarios porque los factores que más influyen en la compra de los usuarios dependen de los caracteres del propio usuario y del artículo por ende aplicaron Baying multinomial naive (MNB) con estos dos grandes conjuntos de características superando a la investigación de [13] en este aspecto .

En [23] se propone el modelo de Bag-of-words , el cual es un nuevo modelo para este contexto, pero también nos menciona que lo usan en conjunto con proyecciones aleatorias para el tema de la curse-of-dimensional que aflige a los modelos bag-of-words. Aunque es modelo nuevo para este contexto, es muy competente en el problema de predicción de ventas

III. METODOLOGÍA DEL DISEÑO DEL MODELO LSTM PARA PREDICCIÓN DE VENTAS

A. Conjunto de Datos

La data es la base de datos de SEMINARIUM PERU S.A.C que alberga 939 tablas. De lo cual se obtuvo 162596 instancias con una cantidad de atributos importantes que se puede escoger para el uso de cualquier técnica.

- sale_order : Tabla de ordenes de ventas
- sale_order_line : Tabla de las líneas de ordenes de ventas
- res_partner : Tabla de clientes
- crm_lead : Tabla de las oportunidades e iniciativas
- crm_phonecall : Tabla de las llamadas

Incluyendo las tablas intermedias.

B. Modelo

TABLE I
VECTOR DE ENTRADA AL LSTM

Variable	Descripción
Monto Total	El monto total de la venta
Tamaño de la empresa del cliente	El tamaño de la empresa que puede ser entre: Grande, mediana o pequeña
Vendedor	El ejecutivo que lo atiende al cliente
¿Vendedor asociado a la empresa?	Si el vendedor coincide con el vendedor asociado de la empresa que se encuentra en el sistema, de lo cual puede ser un SI o un NO.
Cantidad de llamadas	La cantidad de llamadas que se ingresaron

1) *LSTM*: Las formas compactas de las ecuaciones para el paso hacia adelante de una unidad LSTM con una puerta

olvidada son:

$$\begin{aligned} f_t &= \sigma_g(W_f x_t + U_f h_{t-1} + b_f) \\ i_t &= \sigma_g(W_i x_t + U_i h_{t-1} + b_i) \\ o_t &= \sigma_g(W_o x_t + U_o h_{t-1} + b_o) \\ c_t &= f_t \circ c_{t-1} + i_t \circ \sigma_c(W_c x_t + U_c h_{t-1} + b_c) \end{aligned}$$

Además, la t es desde 1 hasta 5, porque es la cantidad de LSTM que habrá debido a que habrá un LSTM por input. La salida es un porcentaje del éxito de la predicción de ventas que es del 0% al 100%

IV. PROCESO DEL MODELO PREDICCIÓN DE VENTAS

A. Extracción

Se extrajo la data mediante un query solo los campos necesarios para esta investigación, para efecto de esta investigación se extrajo en un csv.

```
select cl.id,
extract(YEAR FROM cl.create_date::date) || '-' || extract(MONTH FROM cl.create_date::date) as fecha_orden,
cl.planned_revenue as 'monto_total',
rp.size_company as tamaño_empresa,
cl.user_id as usuario,
(case
when cl.user_id = rp.seller_3 then '1'
when cl.user_id != rp.seller_3 then '0'
else '0'
end) as coincide_vendedor,
(case
when temp_1.count_phonerecall is Null then 0
else temp_1.count_phonerecall
end) as cantidad_llamadas,
ccs.name as probabilidad
...
from crm_lead cl
left join res_partner rp on rp.id = cl.partner_id
left join (select count(*) as count_phonerecall, cp.opportunity_id from crm_phonerecall cp
join crm_lead cl on cl.id = cp.opportunity_id
group by cp.opportunity_id) temp_1 on temp_1.opportunity_id = cl.id
join crm_case_stage ccs on ccs.id = cl.stage_id
where
cl.create_date is not Null and cl.amount_total is not Null and cl.user_id is not Null
and cl.active_order by cl.create_date asc;
```

Fig. 1. Query de extracción

B. Preprocesamiento

1) *Balanceo*: El balanceo se determinó que la mayoría de datos que eran muertos, solo se tomó (cantidad de datos no muertos)*40%, por ende nos salió que la cantidad de no muertos que sería, debía ser de : 11512

```
df_mayoria = df[df.probabilidad=='Muerto']
df_minoria = df[df.probabilidad!='Muerto']
tope_mayoria = len(df_minoria)*0.4
df = pd.concat([df_minoria, df_mayoria[:int(tope_mayoria)]])
print(pd.value_counts(df['probabilidad'], sort = True))
df
```

Fig. 2. Código de balanceo

La data antes del balanceo :

Muerto	133816
Nuevo	24234
Ganado	3439
Con Interés	796
Prospecto	253
Confirmado	58

Name: probabilidad, dtype: int64

Fig. 3. Data antes del balanceo

La data después del balanceo :

Nuevo	24234
Muerto	11512
Ganado	3439
Con Interés	796
Prospecto	253
Confirmado	58

Name: probabilidad, dtype: int64

Fig. 4. Data después del balanceo

De lo cual solo quedó 40292 instancias, después de aplicar el balanceo.

2) *Limpieza*: Se determinó la cantidad de nulos en cada campo.

```
[('monto_total', 35034),
('tamaño_empresa', 11940),
('usuario', 0),
('coincide_vendedor', 0),
('cantidad_llamadas', 0),
('probabilidad', 0)]
```

Fig. 5. Cantidad de nulos

Por lo que vemos que los nulos están presentes en los campos 'monto_total' y 'tamaño_empresa', por lo que se aplicará la siguiente limpieza:

- Al campo 'monto_total' se reemplazó los nulos por 0, al ser un valor continuo.
- Al campo 'tamaño_empresa' se reemplazó los nulos al ser un valor discreto.

Por lo que el resultado es :

	monto_total	tamano_empresa	usuario	coincide_vendedor	cantidad_llamadas	probabilidad
4	1980.00	NaN	16	True	1	Ganado
7	0.00	big	16	True	0	Ganado
9	0.00	big	16	True	0	Ganado
11	5150.00	big	18	True	1	Ganado
21	0.00	big	16	True	1	Prospecto
27	1894.50	NaN	15	True	3	Ganado
28	0.00	big	16	True	0	Con Interés
30	0.00	NaN	16	True	0	Con Interés

	monto_total	tamano_empresa	usuario	coincide_vendedor	cantidad_llamadas	probabilidad
4	1980.00	ninguno	16	True	1	Ganado
7	0.00	big	16	True	0	Ganado
9	0.00	big	16	True	0	Ganado
11	5150.00	big	18	True	1	Ganado
21	0.00	big	16	True	1	Prospecto
27	1894.50	ninguno	15	True	3	Ganado

Fig. 6. Antes y despues de la limpieza de los datos

	monto_total	tamano_empresa	usuario	coincide_vendedor	cantidad_llamadas	probabilidad
4	1980.00	ninguno	16	True	1	Ganado
7	0.00	big	16	True	0	Ganado
9	0.00	big	16	True	0	Ganado
11	5150.00	big	18	True	1	Ganado
21	0.00	big	16	True	1	Prospecto
27	1894.50	ninguno	15	True	3	Ganado

	monto_total	tamano_empresa	usuario	coincide_vendedor	cantidad_llamadas	probabilidad
4	1980.00	0	16	1	1	100
7	0.00	3	16	1	0	100
9	0.00	3	16	1	0	100
11	5150.00	3	18	1	1	100
21	0.00	3	16	1	1	60
27	1894.50	0	15	1	3	100
28	0.00	3	16	1	0	40
30	0.00	0	16	1	0	40

Fig. 7. Antes y despues de la numerización de los datos

C. Correlación

La correlación de los datos fueron:

3) *Numerización*: Se procedio a numerizar los datos cualitativos.

Determinamos un valor por cada valor cuantitativo que tenia cada campo cualitativo. Lo cuales fueron:

- **tamano_empresa:**
 - big : 3
 - medium : 2
 - small : 1
 - ninguno : 0
- **coincide_vendedor:**
 - True : 1
 - False : 0
- **probabilidad:**
 - Ganado : 100
 - Confirmado : 80
 - Prospecto : 60
 - Con interés: 40
 - Nuevo: 20
 - Muerto: 0

Por lo que el resultado es :




Fig. 8. Correlación de los datos

Lo cual la correlación que más nos interesa es la de la probabilidad, puesto que es nuestra variable de predicción del modelo de regresión que estamos planteando.

D. Proceso del LSTM

Se ingresará las variables al LSTM y de acuerdo con el modelo estructurado se predecirá el porcentaje del éxito de la compra.

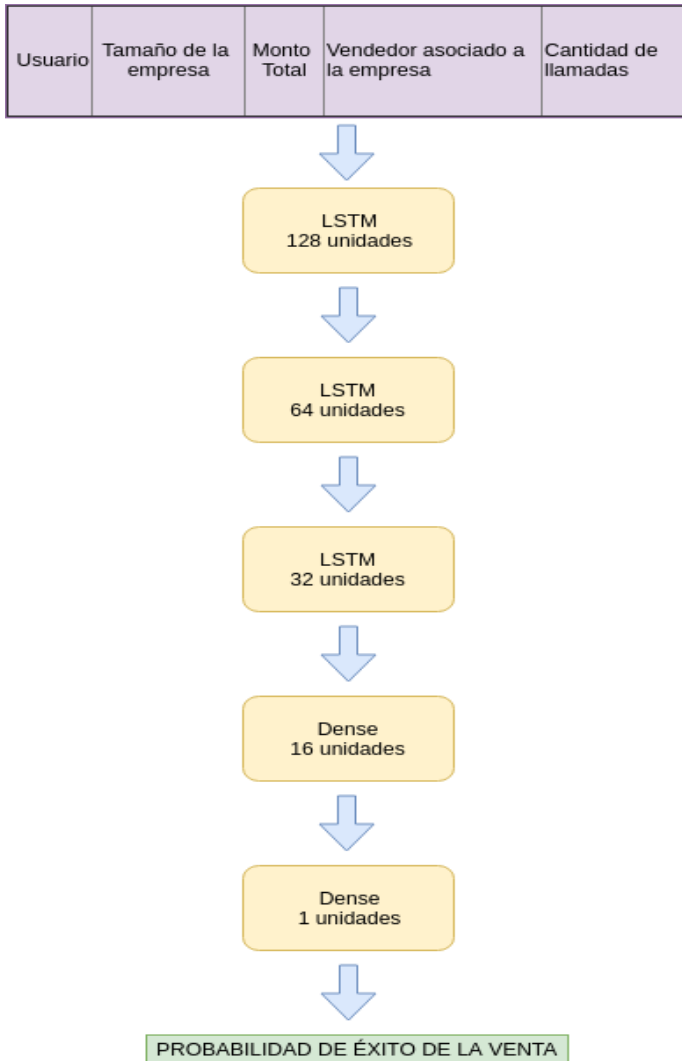


Fig. 9. Proceso del LSTM

Se entreno un LSTM por input y se concatenó en una capa oculta de cual el resultado es la probabilidad de ventas. De lo cual la salida del modelo es:

TABLE II
ESTRUCTURA DE LA SALIDA DEL MODELO DE PREDICCIÓN DE VENTAS.

Variable	Descripcion
0 a 100%	Nos indicara una probabilidad baja de éxito de la compra

V. RESULTADOS

El modelo LSTM, utilizando LSTM para predecir el valor continuo de la probabilidad.

La configuración del modelo LSTM es:

- Épocas: 600
- Batch size (Tamaño de lote): 512
- Optimizador: adam

- Primera capa : 128 unidades
- Segunda capa: 64 unidades
- Tercera capa: 32 unidades
- Función de activación en la última capa: relu
- Función de pérdidas: Error cuadrático medio

El modelo fue entrenado con el 75% de los datos obtenidos y se usó el 25% de los datos para poder evaluar el modelo.

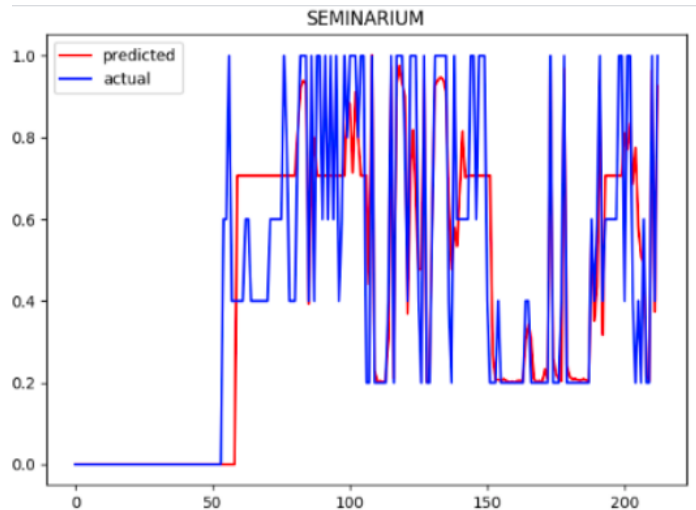


Fig. 10. Predicción de valores de testing

Se puede observar que hay una gran desvariación de la precisión, esto se debe a que el dataset proviene de una empresa real, por lo que la data es muy irregular, además que las variaciones de las ventas, en un entorno real, son muy irregulares en muchos aspectos y esto causa ruido en el modelo.

La pérdida fue disminuyendo por cada época que pasaba, por lo cual se ve claramente como esta constante dentro de un rango de valores 0.0015 a 0.0012 (Fig. 11)




Fig. 11. Pérdida del modelo

De igual manera el error medio absoluto porcentual también se nota constante, aunque haya a veces pequeñas fluctuaciones, debido obviamente algunas fluctuaciones muy distante (Fig. 12)




Fig. 12. Error medio absoluto del modelo

Por ultimo error de la raíz del error cuadrático medio también se nota constante (Fig. 13)




Fig. 13. Raíz del error cuadrático medio del modelo

Entonces los resultados finales son :

TABLE III
RESULTADOS DEL MODELO

Métrica	Resultado
Perdida o Error cuadrático medio	0.0066
Error medio absoluto	0.0200
Error de la raíz cuadrada de la media	0.0200

VI. APLICATIVO

Se desarrollo un aplicativo Web , que esta constituido por :

- BackEnd : Se desarrollo en Flask , y las librerias que usan son :
 - keras
 - blueprints
 - tensorflow
- FrontEnd: Se desarrollo en ReactJS , del cual consume al backend.

Y el resultado fue:

Fig. 14. Aplicativo Web sin Datos

Fig. 15. Aplicativo Web con Datos

Fig. 16. Aplicativo Web con Datos y Resultado

VII. DISCUSION

Las investigaciones [3], [4] (data de apple - data.world) , [20] usan el monto total obtenido en una serie de tiempo , otros como [22] usan algunos datos de ventas , pero solo en el contexto de ventas de moda e incluso alguno como [24] agregaban análisis de sentimientos. Pero la fuente principal

de una venta es el cliente y sobre todo datos tan relevantes como el tamaño de la empresa, sus ventas anteriores e incluso si esta fidelizado con la vendedora. Por lo que el dataset de esta investigación se concentra precisamente en esos datos que en otras investigaciones no han tomado en cuenta.

Después de entrenar el modelo LSTM que predice el éxito de la venta es necesario hacer una comparación del desempeño con otras soluciones ante el problema de predicción de ventas pero en la investigación que se ha realizado hemos detectado que muchos de los autores hablan de la predicción de ventas como el monto total ganado de la venta en un periodo de tiempo [2] [5] [6] que logran entre 95% a 98% de precisión, algunos otros hablan de la predicción de flujo de clientes [11] [12] [13] [14] que logran entre 80% a 85% de precisión e incluso algunos han juntado datos del producto [1] con las de venta en el cual se mide con la métrica R2 que logra un 0.727 , pero ninguno habla de éxito de la predicción de la venta de forma individual contando con las variables de la venta como la del cliente por lo que en esta investigación se desarrolló la predicción de la venta de forma individual del cual el resultado es probabilidad de éxito de la venta y esto permitirá que tanto la gerencia comercial como la gerencia de marketing puedan analizar y “atacar” las ventas de forma más precisa.

En las principales investigaciones de ventas [2] [5] [6] [1] se enfocan en el monto real que se ganaría durante una serie temporal (Año, mes e incluso día), pero no cuentan muchas variables de un entorno real, y además es muy general el monto ganado, de lo cual surge dos grandes preguntas:

- ¿De cómo se ganó ese monto ganado?
- ¿Como puedo mejorar ese monto ganado?

Obviamente las investigaciones de ventas no atacan estas dos preguntas como tal, esto causa de que la empresa no sepa exactamente como mejorar en las ventas y además que tampoco sepa que estrategias poder desplegar, tanto de marketing como comercial. Por lo que en esta investigación tratamos de resolver esos problemas, dando un enfoque más preciso de la venta de forma individual y el éxito que se puede lograr de ella.

Las investigaciones [3] [4] que nos comentan que los modelos híbridos son los más usados en problemas que normalmente una sola técnica de machine learning o deep learning no puede resolverlo, pero el mundo del análisis predictivo de la venta ha sido muy poco usado los híbridos puesto que muchas investigaciones solo se han enfocado en predecir la ganancia total que se generará en un periodo de tiempo; por lo que realizar este análisis en función de otras variables resulta más complejo y se necesita de un modelo más complejo, por eso en esta investigación se optó por el uso de modelo LSTM para determinar el éxito de una venta tomando en cuenta otras variables que otras investigaciones han omitido.

El desarrollo de modelos en escenarios reales es más complicado por la gran cantidad de datos “sucios” lo que causara mucho ruido sino se lograr un óptimo preprocesamiento y limpieza de estos.

CONCLUSIÓN Y TRABAJO FUTURO

Se determino que los mejores modelos de predicción para ventas son modelos basados en Deep learning . Por ende se desarrollo un modelo LSTM para determinar el éxito de una venta tomando en cuenta otras variables que otras investigaciones han omitido. Y tambien el desarrollo de modelos en escenarios reales es más complicado por la gran cantidad de datos “sucios” lo que causara mucho ruido sino se lograr un optimo preprocesamiento y limpieza de estos. Se podría utilizar otros híbridos para manejar variables de ventas en conjunto con las variables del cliente. Y tambien se podria obtener nuevos datos provenientes de otros giros de negocios de ventas para mejorar la cobertura del modelo y no solo empresas B2B.

REFERENCES

- [1] V. L. F. S. A.L.D.Loureiro, "Exploring the use of deep neural networks for sales forecasting in fashion retail", *Decision Support Systems*, pp. 81-93, 2018.
- [2] M. Müller-Navarra, S. Lessmann y S. Voß, "Sales Forecasting with Partial Recurrent Neural Networks: Empirical Insights and Benchmarking Results", de 2015 48th Hawaii International Conference on System Sciences, Kauai, HI, USA, 2015.
- [3] H. Y. Y. G. Z. Z. Shenjia Ji, "Research on Sales Forecasting Based on ARIMA and BP Neural Network Combined Model", de Proceedings of the 2016 International Conference on Intelligent Information Processing, Wuhan, China, 2016.
- [4] S. P. K. J. L. A. J. S. G. U. G. Rankothge Gishan Hiranya Pemathilake, "Sales Forecasting Based on AutoRegressive Integrated Moving Average and Recurrent Neural Network Hybrid Model", de 2018 14th International Conference on Natural Computation, Fuzzy Systems and Knowledge Discovery, Huangshan, China, China, 2018.
- [5] R. S. ., S. Vicky Chrystian Sugianto, "Sales forecasting using Holt-Winters in Enterprise Resource Planning at sales and distribution module", de 2016 International Conference on Information & Communication Technology and Systems (ICTS), Surabaya, Indonesia, 2016.
- [6] H. Y. H. C. L. W. H. W. X. Z. X. L. Tong Chen, "TADA: Trend Alignment with Dual-Attention Multi-Task Recurrent Neural Networks for Sales Prediction", de International Conference on Data Mining, Brisbane,Australia, 2018.
- [7] C. Gallagher, M. G. D'Arcy y M. Brian, "A Bayesian Classification Approach to Improving Performance for a Real-World Sales Forecasting Application", de 2015 IEEE 14th International Conference on Machine Learning and Applications, Miami, FL, USA, 2015.
- [8] Y.-S. W. H.-Y. K. J.-Y. T. ., C.-C. C. H.-. Kuen-Han Tsai, "Multi-Source Learning for Sales Prediction", de 2017 Conference on Technologies and Applications of Artificial Intelligence, Taipei, Taiwan, 2017.
- [9] L. T. V. R. Xin Xu, "Hitting your number or not? A robust & intelligent sales forecast system", de 2017 IEEE International Conference on Big Data (Big Data), Boston, MA, USA, 2017.
- [10] J. Z. X. Z. Zongming Yin, "Forecast customer flow using long short-term memory networks", de 2017 International Conference on Security, Pattern Analysis, and Cybernetics (SPAC), Shenzhen, China, 2017.
- [11] L. Kuo-Yi y J. Jeffrey, "A Deep Learning-Based Customer Forecasting Tool", de 2016 IEEE Second International Conference on Multimedia Big Data (BigMM), Taipei, Taiwan, 2016.
- [12] K. Y. Yuta Kaneko, "A Deep Learning Approach for the Prediction of Retail Store Sales", de 2016 IEEE 16th International Conference on Data Mining Workshops, Barcelona,Spain, 2016.
- [13] A. N. A. H. I. P. Eric Michael Smith, "Forecasting Customer Behaviour in Constrained E-Commerce Platforms", de 8th International Conference of Pattern Recognition Systems (ICPRS 2017), Madrid, Spain , 2017.
- [14] R. Jia, R. Li, M. Yu y S. Wang, "E-commerce purchase prediction approach by user behavior data", de 2017 International Conference on Computer, Information and Telecommunication Systems (CITS), Dalian, China, 2017.

- [15] V. C. Sugiarto, R. Sarno y D. Sunaryono, "Sales Forecasting Using Holt-Winters in Enterprise Resource Planning At Sales and Distribution Module", de 2016 International Conference on Information, Communication Technology and System (ICTS), Surabaya, Indonesia, 2016.
- [16] B. Suh, "Sales Teams Aren't Great at Forecasting. Here's How to Fix That.", 19 Marzo 2019. [En línea]. Available: <https://hbr.org/2019/03/sales-teams-arent-great-at-forecasting-heres-how-to-fix-that>.
- [17] B. Hedayati, "How To Access Intelligence: Data-Driven Transformation In Marketing Operations", 10 Abril 2019. [En línea]. Available: <https://www.forbes.com/sites/forbestechcouncil/2019/04/10/how-to-access-intelligence-data-driven-transformation-in-marketing-operations/#7dff34a35a33>.
- [18] L. Bullock, "Content Marketing Lead Generation Tactics That Actually Work In 2019", 28 Marzo 2019. [En línea]. Available: <https://www.forbes.com/sites/lilachbullock/2019/03/28/content-marketing-lead-generation-tactics-that-actually-work-in-2019/#653239c46c0c>.
- [19] V. Antonio, "How AI Is Changing Sales", 30 Julio 2018. [En línea]. Available: <https://hbr.org/2018/07/how-ai-is-changing-sales>.
- [20] Y. K. P. S. S. U. ., V. S. a. S. B. Mohit Gurnani, "Forecasting of sales by using fusion of Machine Learning techniques", de 2017 International Conference on Data Management, Analytics and, Pune, India, 2017.
- [21] S. Ren, T.-M. Choi y N. Liu, "Fashion Sales Forecasting With a Panel Data-Based Particle-Filter Model", IEEE Transactions on Systems, Man, and Cybernetics: Systems, vol. 45, n° 3, pp. 411-421, 2015.
- [22] P.C.L.Hui y T.-M.Choi, "Using artificial neural networks to improve decision making in apparel supply chain systems", Information Systems for the Fashion and Apparel Industry, n° 5, pp. 97-107, 2016.
- [23] Z. L. K. Rotenberg, "Sales Forecasting Methods", 2014. [En línea].
- [24] M. J. Schneider y S. Gupta, "Forecasting sales of new and existing products using consumer reviews : A random projections approach", International Journal of Forecasting, vol. 32, n° 2, pp. 243-256, 2016.